

Министерство науки и высшего образования Российской Федерации

Федеральное государственное бюджетное образовательное учреждение

высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

ОТЧЕТ по лабораторной работе № 3

Дисциплина: <u>Технологии машинного обучения</u>
Тема: «Подготовка обучающей и тестовой выборки, кросс-валлидация и подбор гиперпараметров на примере метода ближайших соседей»

Студент	ИУ5Ц-82Б		А.Н. Свинцов
	(Группа)	(Подпись, дата	(И.О. Фамилия)
Преподаватель			Ю.Е. Гапанюк
		(Подпись, дата	(И.О. Фамилия)
Преподаватель			А.Н. Нардид
		(Подпись, дата	(И.О. Фамилия)

Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей.

Подключение библиотек

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib
import matplotlib_inline
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")

Загрузка данных
data = pd.read_csv('cwurData.csv', sep=",")
```

Описание столбцов:

- world_rank мировой рейтинг университета
- institution название университета
- · country страна, в которой расположен университет
- national_rank рейтинг университета в стране его нахождения
- quality_of_education рейтинг качества образования
- quality_of_faculty рейтинг качества профессорскопреподавательского состава
- publications рейтинг публикаций
- infuence рейтинг влияния
- citations количество студентов в университете
- broad_impact рейтинг за широкое влияние (предоставлен только за 2014 и 2015 гг. Остальное пропуски)
- patents рейтинг за патенты
- score общий балл, используемый для определения мирового рейтинга
- year год рейтинга (с 2012 по 2015 год)

Основные характеристики

```
0
     world rank
                            2200 non-null
                                             int64
 1
     institution
                            2200 non-null
                                             object
2
     country
                            2200 non-null
                                             object
3
     national rank
                            2200 non-null
                                             int64
 4
     quality of education
                            2200 non-null
                                             int64
     alumni employment
 5
                            2200 non-null
                                             int64
 6
     quality of faculty
                            2200 non-null
                                             int64
 7
     publications
                            2200 non-null
                                             int64
 8
     influence
                            2200 non-null
                                             int64
 9
     citations
                            2200 non-null
                                             int64
 10
    broad impact
                            2000 non-null
                                             float64
                                             int64
 11
    patents
                            2200 non-null
 12
     score
                                             float64
                            2200 non-null
 13
                            2200 non-null
                                             int64
    vear
dtypes: float64(2), int64(10), object(2)
memory usage: 240.8+ KB
#Размер
data.shape
(2200, 14)
#Типы данных
data.dtypes
world rank
                           int64
institution
                          object
country
                          object
national rank
                           int64
quality_of_education
                           int64
alumni employment
                           int64
quality_of_faculty
                           int64
publications
                           int64
influence
                           int64
citations
                           int64
broad impact
                         float64
patents
                           int64
```

float64 int64

dtype: object

score

year

#Проверка на пропуски

data.isnull().sum()

world_rank	0
institution	0
country	0
national_rank	0
quality_of_education	0
alumni_employment	0
quality of faculty	0

<pre>publications influence citations broad_impact patents score year dtype: int64</pre>		0 0 200 0 0				
data.head()						
world_rank				institution		
country \ 0 1			Harva	rd University		USA
1 2	Ma	assachusetts	Institute o	of Technology		USA
2 3			Stanfo	rd University		USA
3 4			University	of Cambridge	United	Kingdom
4 5		California	Institute o	of Technology		USA
national_raquality_of_face 0 1 1 3 2 5 3 4 4 7			_education	alumni_employ	yment 9 17 11 24 29	
publication	ns	influence o	citations I	oroad_impact	patents	score
year 0	1	1	1	NaN	5	100.00
	12	4	4	NaN	1	91.67
2012 2	4	2	2	NaN	15	89.50
	16	16	11	NaN	50	86.17
2012 4 2012	37	22	22	NaN	18	85.21

```
#Процент пропусков в колонке broad impact
(200 / 2200) * 100
9.090909090909092
# Задание формата графиков для сохранения высокого качества PNG
from IPvthon.display import set matplotlib formats
matplotlib inline.backend inline.set matplotlib formats("retina")
# Задание ширины графиков, чтобы они помещались на А4
pd.set_option("display.width", 70)
Обработка пропусков
Очитска строк
# Удаление строк, содержащих пустые значения
data no null = data.dropna(axis=0, how='any')
(data.shape, data no null.shape)
((2200, 14), (2000, 14))
total count = data no null.shape[0]
print('Bcero ctpok: {}'.format(total count))
Всего строк: 2000
Кодирование категориальных признаков
Преобразование стран, университетов в числовые значения
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
Кодирование университетов
le = LabelEncoder()
institution le = le.fit transform(data no null['institution'])
data no null['institution'].unique()
array(['Harvard University', 'Stanford University',
       'Massachusetts Institute of Technology', ...,
       'Babes-Bolyai University', 'Henan Normal University',
       'Southwest Jiaotong University'], dtype=object)
arr institution encoded = np.unique(institution le)
arr_institution_encoded
                      2, ..., 1020, 1021, 1022])
array([
                1,
          0,
le.inverse transform([n for n in range(1023)])
array(['AGH University of Science and Technology', 'Aalborg
University',
       'Aalto University', ..., 'École normale supérieure de Cachan',
```

```
'École normale supérieure de Lyon', 'Örebro University'],
        dtype=object)
Кодирование стран
le country = LabelEncoder()
country le = le country.fit transform(data no null['country'])
data no null['country'].unique()
'South Africa', 'Spain', 'Brazil', 'Hong Kong', 'Ireland', 'Austria', 'New Zealand', 'Portugal', 'Thailand', 'Czech
         'Malaysia', 'India', 'Greece', 'Mexico', 'Hungary',
'Argentina',
         'Turkey', 'Poland', 'Saudi Arabia', 'Chile', 'Iceland',
'Slovenia',
         'Estonia', 'Lebanon', 'Croatia', 'Colombia', 'Slovak Republic',
         'Iran', 'Egypt', 'Serbia', 'Bulgaria', 'Lithuania', 'Uganda',
         'United Arab Emirates', 'Uruguay', 'Cyprus', 'Romania',
         'Puerto Rico'], dtype=object)
np.unique(country le)
array([ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15,
16,
         17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32,
33,
         34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49,
50,
         51, 52, 53, 54, 55, 56, 57, 58])
le country.inverse transform([n for n in range(59)])
array(['Argentina', 'Australia', 'Austria', 'Belgium', 'Brazil',
         'Bulgaria', 'Canada', 'Chile', 'China', 'Colombia', 'Croatia', 'Cyprus', 'Czech Republic', 'Denmark', 'Egypt', 'Estonia', 'Finland', 'France', 'Germany', 'Greece', 'Hong Kong',
'Hungary',
         'Iceland', 'India', 'Iran', 'Ireland', 'Israel', 'Italy',
'Japan',
         'Lebanon', 'Lithuania', 'Malaysia', 'Mexico', 'Netherlands', 'New Zealand', 'Norway', 'Poland', 'Portugal', 'Puerto Rico', 'Romania', 'Russia', 'Saudi Arabia', 'Serbia', 'Singapore', 'Slovak Republic', 'Slovenia', 'South Africa', 'South Korea', 'Spain', 'Sweden', 'Switzerland', 'Taiwan', 'Thailand',
'Turkey',
```

```
'USA', 'Uganda', 'United Arab Emirates', 'United Kingdom',
        'Uruguay'], dtype=object)
data no null.head()
     world rank
                                              institution
200
                                      Harvard University
               1
               2
                                     Stanford University
201
               3
202
                  Massachusetts Institute of Technology
203
               4
                                 University of Cambridge
               5
                                    University of Oxford
204
                      national rank quality of education
             country
200
                 USA
201
                 USA
                                   2
                                                          11
                                   3
                                                           3
202
                 USA
                                                           2
203
     United Kingdom
                                   1
     United Kingdom
                                   2
                                                           7
204
     alumni employment
                         quality_of_faculty
                                               publications
                                                              influence
200
                      1
                                            1
                                                                       1
                      2
                                                           5
201
                                            4
                                                                       3
202
                     11
                                            2
                                                          15
                                                                       2
                                            5
                                                                       9
203
                     10
                                                          10
204
                     12
                                           10
                                                          11
                                                                      12
                 broad impact patents
     citations
                                           score
                                                  year
200
                           1.0
                                          100.00
              1
                                      2
                                                  2014
              3
                           4.0
201
                                      6
                                           99.09
                                                  2014
              2
202
                           2.0
                                      1
                                           98.69
                                                  2014
203
             12
                                     48
                                           97.64 2014
                         13.0
204
             11
                          12.0
                                     16
                                           97.51
                                                  2014
data digit = data no null.copy()
#data digit.pop('institution')
#data digit.pop('country')
data digit["institution"] = institution le
data digit['country'] = country le
data digit
                  institution
                                           national rank
      world rank
                                 country
200
                                      54
                1
                            184
                                                        1
                2
                                      54
                                                        2
201
                            511
202
                3
                            312
                                      54
                                                        3
                                                        1
203
                4
                            637
                                      57
                5
                                                        2
204
                            819
                                      57
                            . . .
. . .
              . . .
                                      . . .
                                                      . . .
                                                       7
                            954
2195
              996
                                      37
2196
              997
                             11
                                      14
                                                       4
2197
              998
                            132
                                       4
                                                       18
2198
              999
                            576
                                      48
                                                       40
```

```
1000
                              74
2199
                                          8
                                                          83
      quality_of_education
                              alumni employment
                                                     quality_of_faculty
200
                            1
201
                           11
                                                  2
                                                                        4
                                                                         2
202
                            3
                                                 11
                            2
                                                                        5
203
                                                 10
204
                            7
                                                 12
                                                                       10
. . .
2195
                          367
                                                567
                                                                      218
2196
                          236
                                               566
                                                                      218
                          367
2197
                                               549
                                                                      218
2198
                          367
                                               567
                                                                      218
2199
                          367
                                               567
                                                                      218
      publications
                      influence
                                  citations
                                               broad impact
                                                               patents
200
                   1
                                1
                                            1
                                                          1.0
                                                                      2
                   5
                                3
                                            3
                                                          4.0
201
                                                                      6
                               2
202
                  15
                                            2
                                                          2.0
                                                                      1
                               9
203
                  10
                                           12
                                                         13.0
                                                                     48
                              12
204
                  11
                                           11
                                                         12.0
                                                                     16
2195
                 926
                             845
                                          812
                                                       969.0
                                                                    816
2196
                 997
                             908
                                          645
                                                       981.0
                                                                    871
                 830
                                          812
2197
                             823
                                                       975.0
                                                                    824
2198
                 886
                             974
                                          812
                                                       975.0
                                                                    651
2199
                 861
                             991
                                          812
                                                       981.0
                                                                    547
        score
               year
200
      100.00
                2014
        99.09
201
                2014
202
        98.69
                2014
203
        97.64
                2014
204
        97.51
               2014
. . .
                . . .
          . . .
        44.03
                2015
2195
2196
        44.03
                2015
2197
        44.03
                2015
2198
        44.02
               2015
2199
        44.02
               2015
[2000 rows \times 14 columns]
Проверим новые типы данных
data digit.dtypes
world rank
                             int64
institution
                             int32
country
                             int32
```

int64

national rank

```
quality_of_education
                            int64
alumni_employment
                            int64
quality_of_faculty
                            int64
publications
                            int64
influence
                           int64
citations
                           int64
broad impact
                         float64
patents
                            int64
score
                         float64
year
                            int64
```

dtype: object

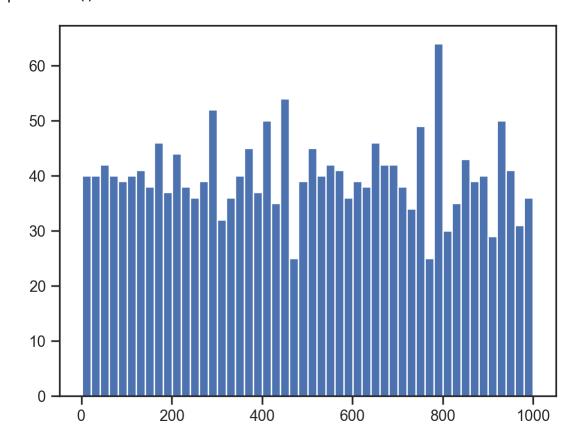
Масштабирование

from sklearn.preprocessing import MinMaxScaler, StandardScaler,
Normalizer

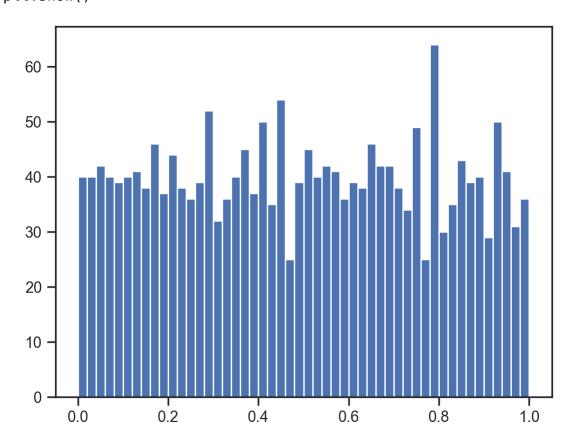
Min Max

```
world_rank
```

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data_digit[['broad_impact']])
plt.hist(data_digit['broad_impact'], 50)
plt.show()
```

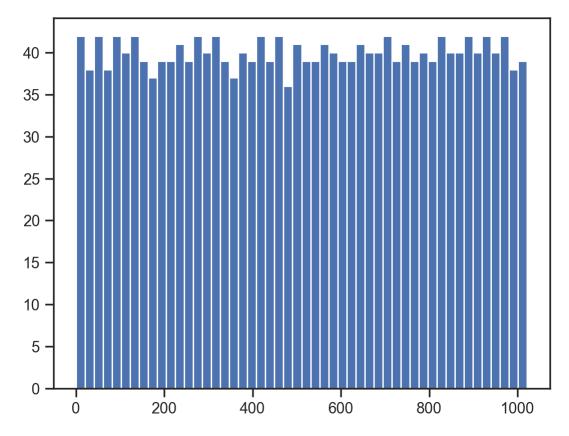


```
plt.hist(sc1_data, 50)
plt.show()
```

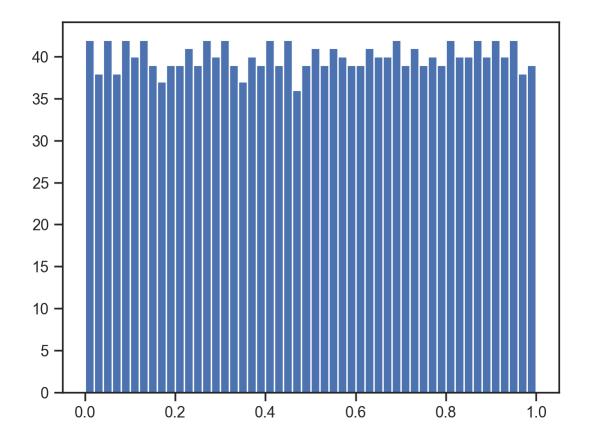


institution

```
sc2 = MinMaxScaler()
sc2_data = sc2.fit_transform(data_digit[['institution']])
plt.hist(data_digit['institution'], 50)
plt.show()
```

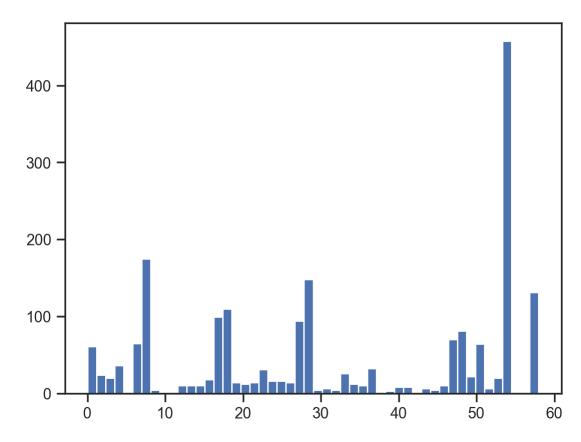


plt.hist(sc2_data, 50)
plt.show()

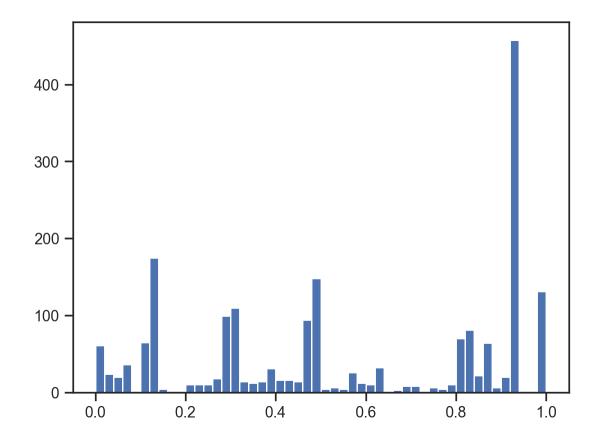


country

```
sc3 = MinMaxScaler()
sc3_data = sc3.fit_transform(data_digit[['country']])
plt.hist(data_digit['country'], 50)
plt.show()
```

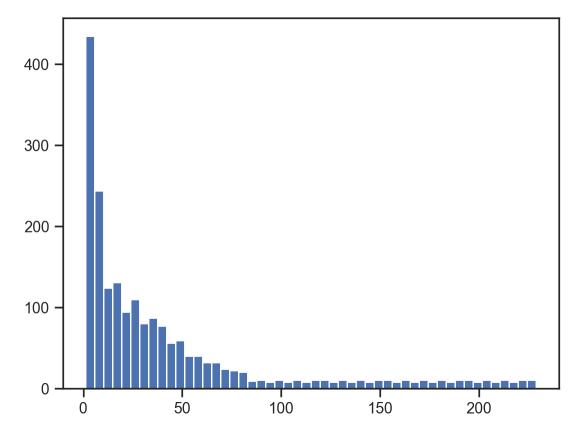


plt.hist(sc3_data, 50)
plt.show()

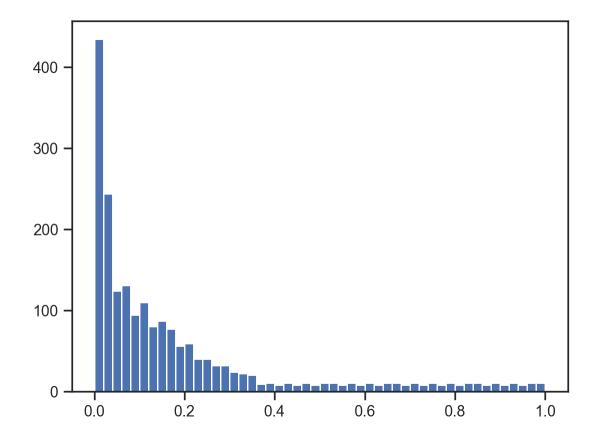


natioanal_rank

```
sc4 = MinMaxScaler()
sc4_data = sc4.fit_transform(data_digit[['national_rank']])
plt.hist(data_digit['national_rank'], 50)
plt.show()
```

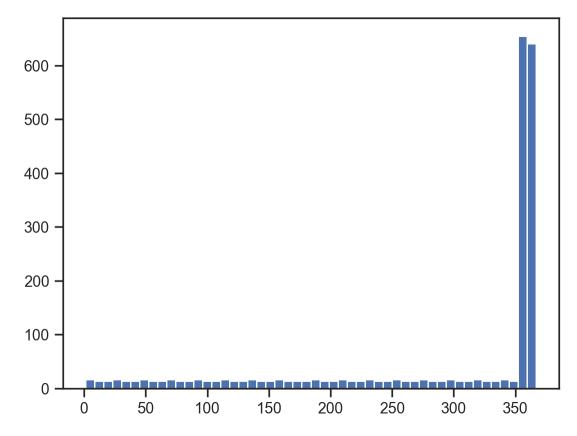


plt.hist(sc4_data, 50)
plt.show()

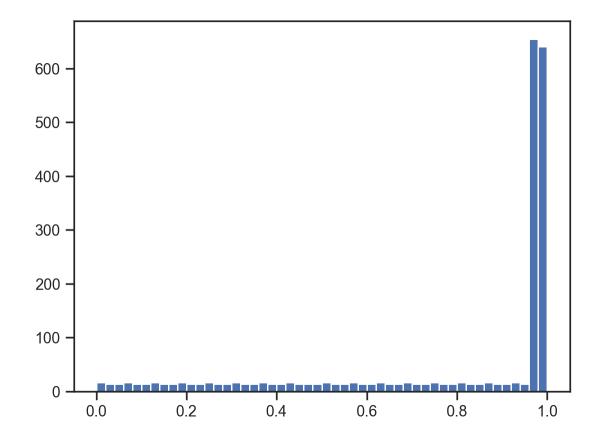


```
quality_of_education
```

```
sc5 = MinMaxScaler()
sc5_data = sc5.fit_transform(data_digit[['quality_of_education']])
plt.hist(data_digit['quality_of_education'], 50)
plt.show()
```

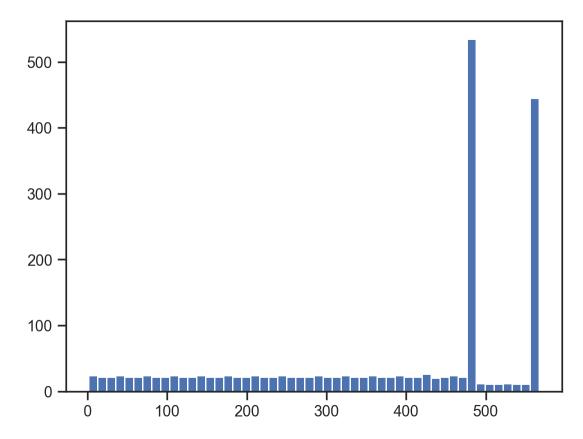


plt.hist(sc5_data, 50)
plt.show()

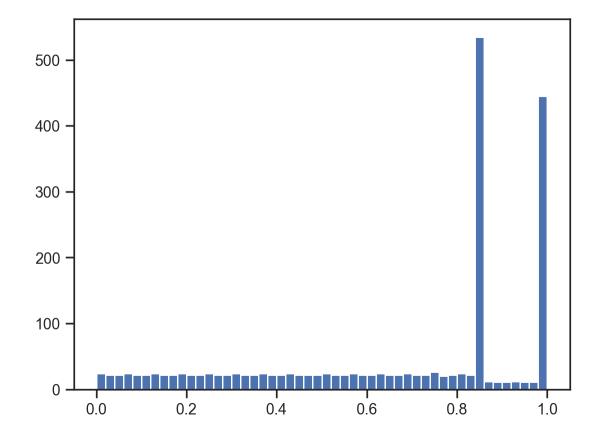


alumni_employment

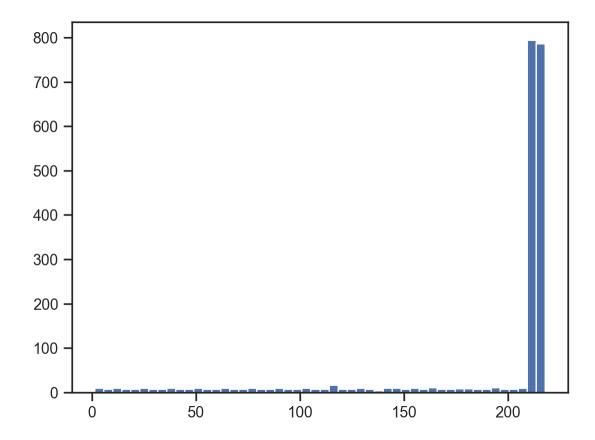
```
sc6 = MinMaxScaler()
sc6_data = sc6.fit_transform(data_digit[['alumni_employment']])
plt.hist(data_digit['alumni_employment'], 50)
plt.show()
```



plt.hist(sc6_data, 50)
plt.show()

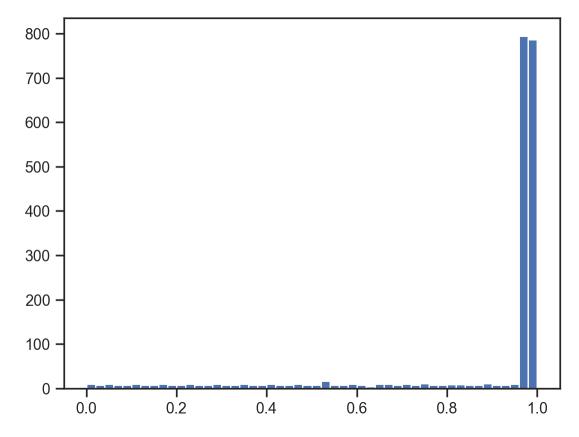


```
quality_of_faculty
sc7 = MinMaxScaler()
sc7_data = sc7.fit_transform(data_digit[['quality_of_faculty']])
plt.hist(data_digit['quality_of_faculty'], 50)
plt.show()
```

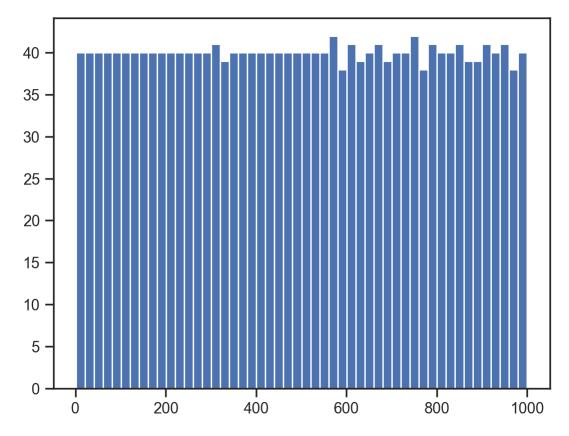


publications

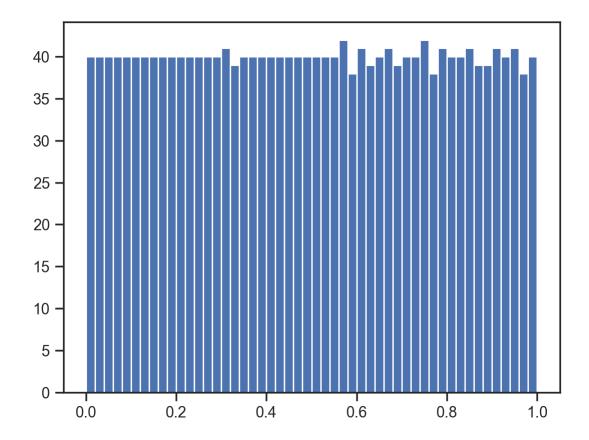
plt.hist(sc7_data, 50)
plt.show()



```
sc8 = MinMaxScaler()
sc8_data = sc8.fit_transform(data_digit[['publications']])
plt.hist(data_digit['publications'], 50)
plt.show()
```

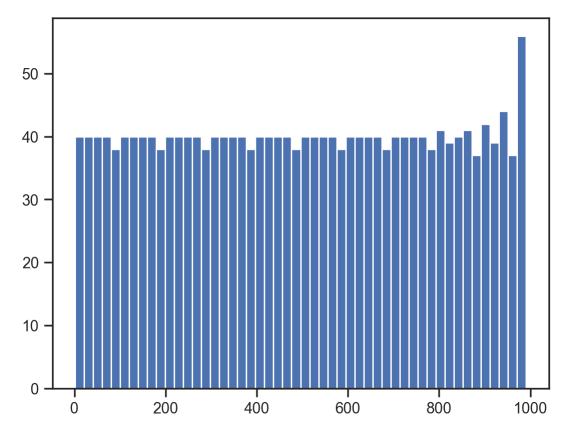


plt.hist(sc8_data, 50)
plt.show()

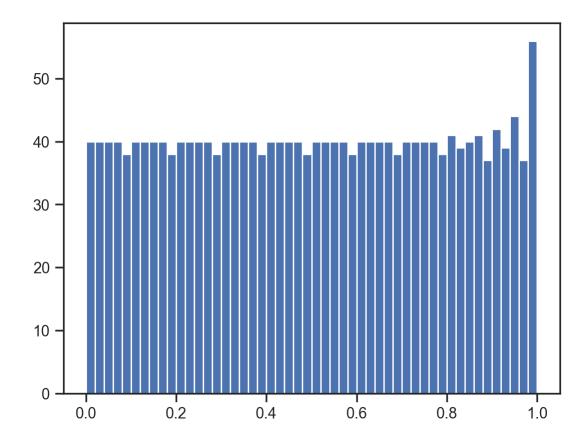


influence

```
sc9 = MinMaxScaler()
sc9_data = sc9.fit_transform(data_digit[['influence']])
plt.hist(data_digit['influence'], 50)
plt.show()
```

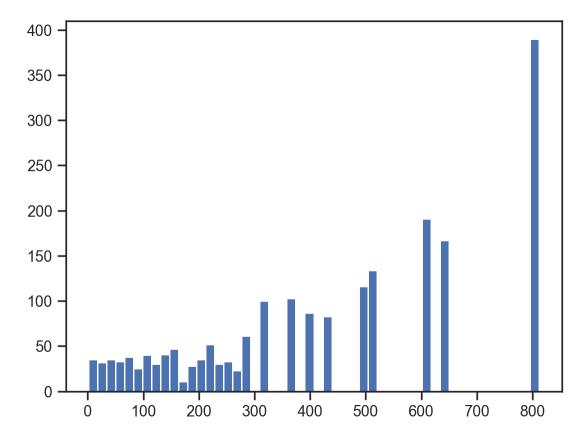


plt.hist(sc9_data, 50)
plt.show()

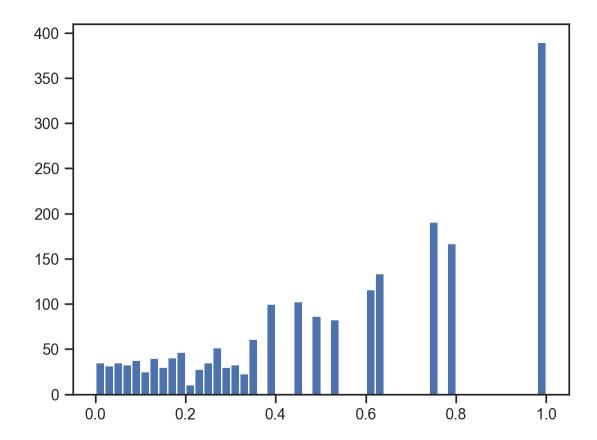


citations

```
sc10 = MinMaxScaler()
sc10_data = sc10.fit_transform(data_digit[['citations']])
plt.hist(data_digit['citations'], 50)
plt.show()
```

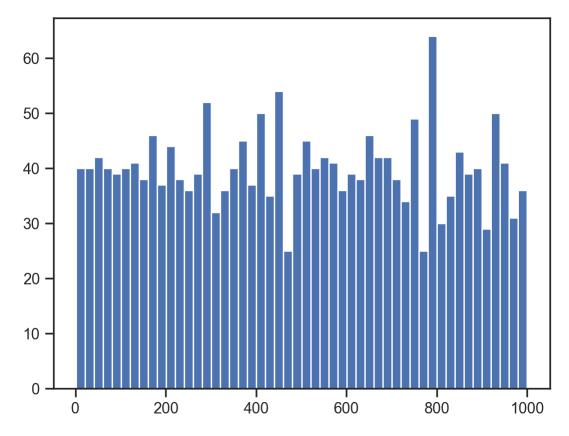


plt.hist(sc10_data, 50)
plt.show()

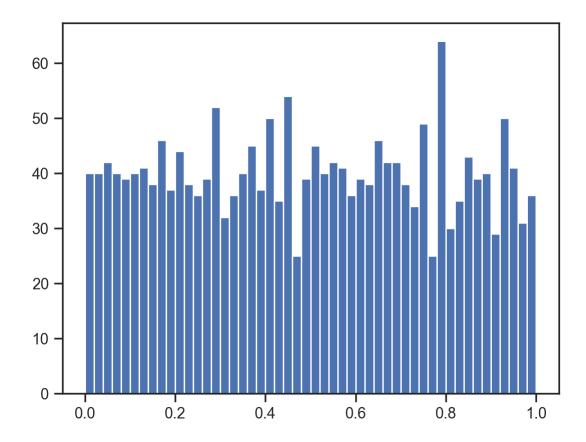


broad_impact

```
scl1 = MinMaxScaler()
scl1_data = scl1.fit_transform(data_digit[['broad_impact']])
plt.hist(data_digit['broad_impact'], 50)
plt.show()
```

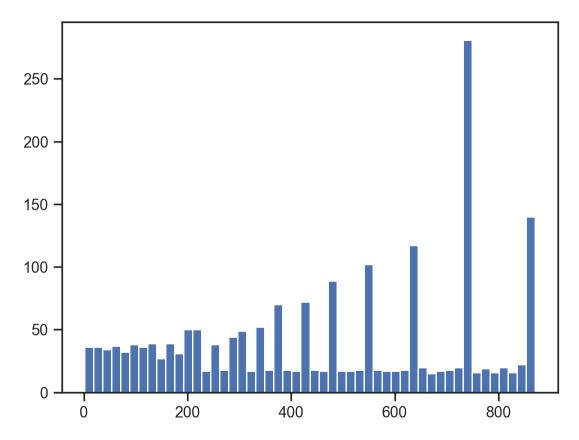


plt.hist(sc11_data, 50)
plt.show()

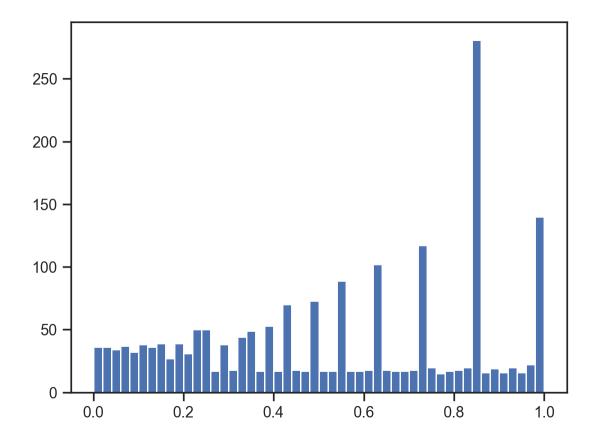


patents

```
sc12 = MinMaxScaler()
sc12_data = sc12.fit_transform(data_digit[['patents']])
plt.hist(data_digit['patents'], 50)
plt.show()
```

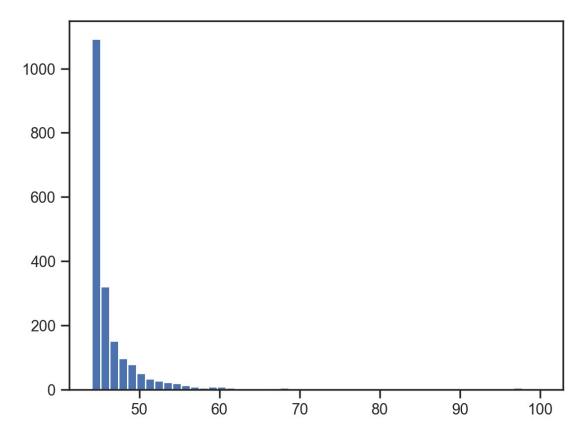


plt.hist(sc12_data, 50)
plt.show()

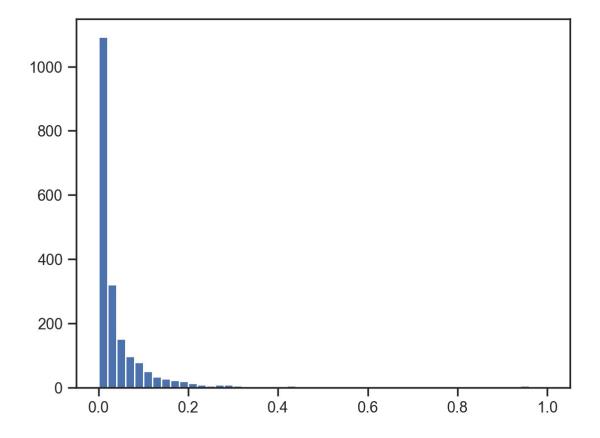


```
score
```

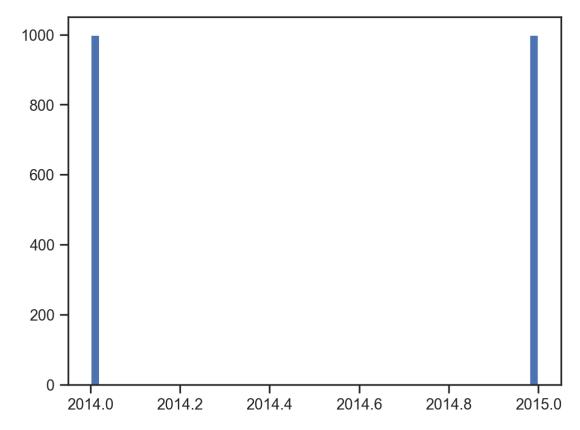
```
sc13 = MinMaxScaler()
sc13_data = sc13.fit_transform(data_digit[['score']])
plt.hist(data_digit['score'], 50)
plt.show()
```



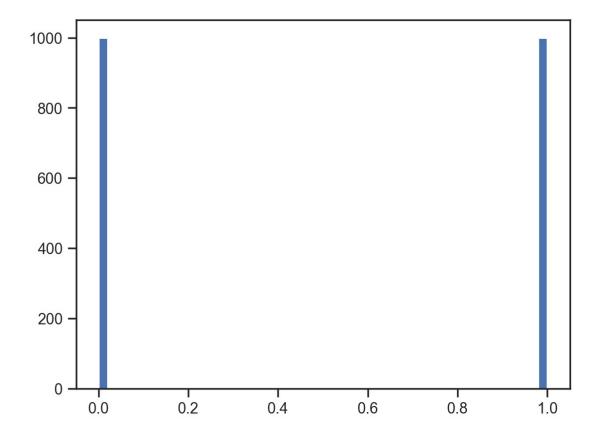
plt.hist(sc13_data, 50)
plt.show()



```
year
sc14 = MinMaxScaler()
sc14_data = sc14.fit_transform(data_digit[['year']])
plt.hist(data_digit['year'], 50)
plt.show()
```



plt.hist(sc14_data, 50)
plt.show()



Сборка отмасштабированных данных в датасет

```
data_normal = data_digit.copy()
data_normal['world_rank'] = sc1_data
data_normal['institution'] = sc2_data
data_normal['country'] = sc3_data
data_normal['national_rank'] = sc4_data
data_normal['quality_of_education'] = sc5_data
data_normal['alumni_employment'] = sc6_data
data_normal['quality_of_faculty'] = sc7_data
data_normal['publications'] = sc8_data
data_normal['influence'] = sc9_data
data_normal['citations'] = sc10_data
data_normal['broad_impact'] = sc11_data
data_normal['patents'] = sc12_data
data_normal['year'] = sc13_data
data_normal['year'] = sc14_data
```

data normal

	world_rank	institution	country	national_rank	\
200	$0.0\overline{0}0000$	0.180039	0.931034	$0.0\overline{0}0000$	
201	0.003003	0.500000	0.931034	0.004386	
202	0.001001	0.305284	0.931034	0.008772	
203	0.012012	0.623288	0.982759	0.000000	
204	0.011011	0.801370	0.982759	0.004386	

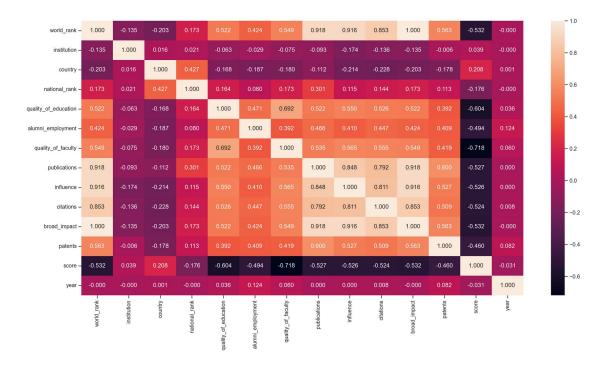
```
0.968969
                                 0.637931
2195
                      0.933464
                                                  0.026316
                      0.010763
                                                  0.013158
2196
        0.980981
                                 0.241379
2197
        0.974975
                      0.129159
                                 0.068966
                                                  0.074561
2198
        0.974975
                      0.563601
                                 0.827586
                                                  0.171053
2199
        0.980981
                      0.072407
                                 0.137931
                                                  0.359649
      quality of education
                              alumni employment
                                                   quality of faculty
200
                   0.000000
                                        0.000000
                                                              0.000000
201
                   0.027322
                                        0.001767
                                                              0.013825
202
                   0.005464
                                        0.017668
                                                              0.004608
203
                   0.002732
                                        0.015901
                                                              0.018433
204
                   0.016393
                                        0.019435
                                                              0.041475
2195
                   1.000000
                                        1.000000
                                                              1.000000
                                        0.998233
2196
                   0.642077
                                                              1.000000
2197
                   1.000000
                                        0.968198
                                                              1.000000
2198
                   1.000000
                                        1.000000
                                                              1.000000
2199
                   1.000000
                                        1.000000
                                                              1.000000
                     influence
      publications
                                 citations
                                             broad impact
                                                              patents
                                                  0.000000
200
          0.000000
                      0.00000
                                  0.00000
                                                             0.001149
201
          0.004004
                      0.002020
                                  0.002466
                                                  0.003003
                                                             0.005747
202
          0.014014
                      0.001010
                                  0.001233
                                                  0.001001
                                                             0.00000
203
          0.009009
                      0.008081
                                  0.013564
                                                  0.012012
                                                             0.054023
204
          0.010010
                      0.011111
                                  0.012330
                                                  0.011011
                                                             0.017241
          0.925926
                      0.852525
                                  1.000000
                                                  0.968969
                                                             0.936782
2195
2196
          0.996997
                      0.916162
                                  0.794081
                                                  0.980981
                                                             1.000000
2197
          0.829830
                      0.830303
                                  1.000000
                                                  0.974975
                                                             0.945977
2198
          0.885886
                      0.982828
                                  1.000000
                                                  0.974975
                                                             0.747126
2199
          0.860861
                      1.000000
                                  1.000000
                                                  0.980981
                                                             0.627586
         score
                 year
200
      1.000000
                  0.0
201
      0.983744
                  0.0
202
      0.976599
                  0.0
203
      0.957842
                  0.0
204
      0.955520
                  0.0
2195
      0.000179
                  1.0
2196
      0.000179
                  1.0
2197
      0.000179
                  1.0
2198
      0.000000
                  1.0
2199
      0.000000
                  1.0
```

Проверим корреляцию

[2000 rows x 14 columns]

```
fig, ax = plt.subplots(1, 1, sharex='col', sharey='row', figsize=(20,10)) fig.suptitle('Корреляционная матрица') sns.heatmap(data_normal.corr(), ax=ax, annot=True, fmt='.3f') <AxesSubplot: >
```

Корреляционная матрица



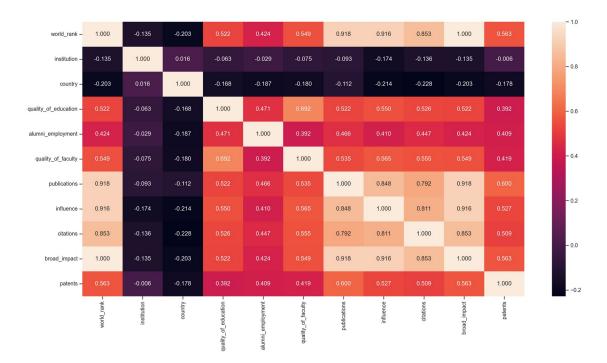
По матрице корреляции заметим, для определения целевого признака (world_rank) нужно знать только рейтинг за широкое влияние (broad_impact), поскольку коэффициент кореляции = 1,000

Год (year) вобще не корелирует с целевым признаком (коефициент = 0,000). Исключим из модели

```
data_normal = data_normal.drop(columns='year')
data_normal = data_normal.drop(columns='national_rank')
data_normal = data_normal.drop(columns='score')

fig, ax = plt.subplots(1, 1, sharex='col', sharey='row',
figsize=(20,10))
fig.suptitle('Корреляционная матрица')
sns.heatmap(data_normal.corr(), ax=ax, annot=True, fmt='.3f')

<AxesSubplot: >
```



Разделение выборки на обучающую и тестовую

```
from sklearn.model selection import train test split, cross val score,
LeaveOneOut, GridSearchCV
```

from sklearn.neighbors import KNeighborsRegressor,

KNeighborsClassifier

from sklearn.metrics import accuracy_score, explained_variance_score, mean_absolute_error, max_error

В исходном наборе данных целевой признак не отделён от остальных данных, поэтому выделим набор данных, не содержащий world_rank

```
data x = data normal.copy()
data x = data x.drop(columns='world rank')
data x
```

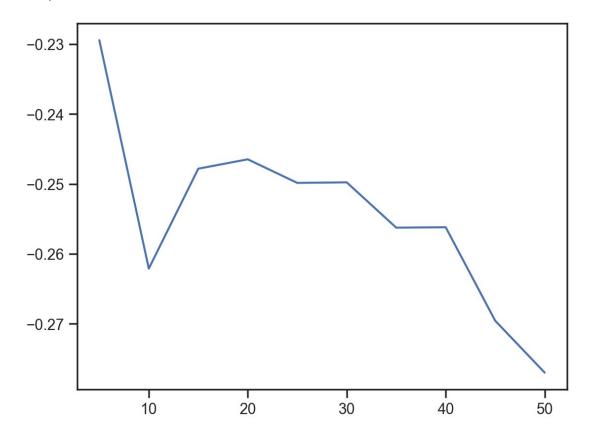
	institution	country	quality_of_education	\
200	0.180039	0.931034	0.00000	
201	0.500000	0.931034	0.027322	
202	0.305284	0.931034	0.005464	
203	0.623288	0.982759	0.002732	
204	0.801370	0.982759	0.016393	
2195	0.933464	0.637931	1.000000	
2196	0.010763	0.241379	0.642077	
2197	0.129159	0.068966	1.000000	
2198	0.563601	0.827586	1.000000	
2199	0.072407	0.137931	1.000000	

```
alumni employment
                          quality of faculty
                                                publications
200
                                     0.000000
                0.00000
                                                    0.000000
201
                0.001767
                                     0.013825
                                                    0.004004
202
                0.017668
                                     0.004608
                                                    0.014014
203
                0.015901
                                     0.018433
                                                    0.009009
204
                0.019435
                                     0.041475
                                                    0.010010
. . .
2195
                1.000000
                                     1.000000
                                                    0.925926
2196
                0.998233
                                     1.000000
                                                    0.996997
2197
                0.968198
                                     1.000000
                                                    0.829830
2198
                1.000000
                                     1.000000
                                                    0.885886
2199
                1.000000
                                     1.000000
                                                    0.860861
      influence
                  citations
                              broad impact
                                              patents
200
       0.000000
                   0.000000
                                  0.000000
                                            0.001149
201
       0.002020
                   0.002466
                                  0.003003
                                            0.005747
202
       0.001010
                   0.001233
                                  0.001001
                                             0.00000
203
       0.008081
                   0.013564
                                  0.012012
                                             0.054023
                   0.012330
204
       0.011111
                                  0.011011
                                            0.017241
2195
       0.852525
                   1.000000
                                  0.968969
                                            0.936782
2196
       0.916162
                   0.794081
                                  0.980981
                                             1.000000
2197
       0.830303
                   1.000000
                                  0.974975
                                            0.945977
2198
       0.982828
                   1.000000
                                  0.974975
                                             0.747126
2199
       1.000000
                   1.000000
                                  0.980981
                                             0.627586
[2000 rows \times 10 columns]
data y = data normal['world rank']
data y
200
        0.00000
201
        0.003003
202
        0.001001
203
        0.012012
204
        0.011011
2195
        0.968969
2196
        0.980981
2197
        0.974975
        0.974975
2198
2199
        0.980981
Name: world rank, Length: 2000, dtype: float64
Зададим тестовую выборку с размером 10%
data X train, data_X_test, data_y_train, data_y_test =
train test split(data x, data y, test size=0.2, random state=2022)
```

Метод ближайших соседей

```
Первичное обучение модели и оценка качества
#cll 1 = KNeighborsClassifier(n neighbors=3) # Классификация в данной
задаче не работает
cl1 1 = KNeighborsRegressor(n neighbors=3) # Используем регрессию
cll_1.fit(data_X_train, data_y_train)
target1 0 = cl1 1.predict(data X train)
target1 1 = cl1 1.predict(data X test)
#accuracy_score(data_y_train, target1_0), accuracy_score(data_y_test,
target1 1)
max error(data y train, target1 0), max error(data y test, target1 1)
(0.17584250917584254, 0.21688355021688355)
Оценка качества модели с использованием кросс-валидации
#scores = cross val score(KNeighborsRegressor(n neighbors=3), data x,
data y, cv=LeaveOneOut()) # bug
https://github.com/scikit-learn/scikit-learn/issues/11435
scores = cross val score(KNeighborsRegressor(n neighbors=3), data x,
data y, cv=5)
scores, np.mean(scores)
(array([0.90762872, 0.78141885, 0.98239803, 0.8687708, 0.79487252]),
0.8670177827458012)
n range = np.array(range(5,55,5))
tuned parameters = [{'n neighbors': n range}]
tuned parameters
[{'n_neighbors': array([ 5, 10, 15, 20, 25, 30, 35, 40, 45, 50])}]
Получим максимальную остаточную ошибку, используя всю выборку
%%time
reg gs = GridSearchCV(KNeighborsRegressor(), tuned parameters, cv=3,
scoring='max error')
reg gs.fit(data x, data y)
CPU times: total: 1.19 s
Wall time: 1.19 s
GridSearchCV(cv=3, estimator=KNeighborsRegressor(),
             param grid=[{'n neighbors': array([ 5, 10, 15, 20, 25,
30, 35, 40, 45, 50])}],
             scoring='max error')
reg gs.best params
{'n neighbors': 5}
plt.plot(n_range, reg_gs.cv_results_['mean_test_score'])
```

[<matplotlib.lines.Line2D at 0x26bb6efa890>]



Обучение модели и оценка качества с учетом подобранных гиперпараметров

```
reg_gs.best_estimator_.fit(data_X_train, data_y_train)
target2_0 = reg_gs.best_estimator_.predict(data_X_train)
target2_1 = reg_gs.best_estimator_.predict(data_X_test)
```

Проверка нового качества модели

max_error(data_y_train, target1_0), max_error(data_y_test, target1_1)
(0.17584250917584254, 0.21688355021688355)

Качество модели до подбора гиперпараметров

```
max_error(data_y_train, target1_0), max_error(data_y_test, target1_1)
(0.17584250917584254, 0.21688355021688355)
```

Из этих данных видно, что ошибка составляет не более 21,6% при использовании метода ближайших соседей